

GS-PINO 算法技术详解：从 FNO 到 Transformer 的架构家族与两阶段物理约束训练

写给谁：想弄懂这套代码里"到底用了什么算法、为什么这么设计、各方法什么关系"的初学者——不需要物理或深度学习的预先知识，但建议会一点 Python 和基本微积分。

覆盖内容：Grad-Shafranov (GS) 平衡求解问题；8 种网络架构 (FNO、U-Net、UFNO、FNO-KAN、PI-DeepONet、POD-DeepONet、Transformer [实验代号 TKNO-lite]、点式 KAN) 各自的思想、结构、公式与实验结果；两阶段物理约束 (PINO) 训练方法；以及整个实验系列 (exp101–312) 串起来的结论链。

对应代码：[src/gs_pino_fno_phys/models_alt.py](#)、[src/gs_pino/model](#) 目录、[train_pino.py](#)、[losses_pino.py](#)。
完整实验档案见 [EXPERIMENTS.md](#)。

0. 一页速览

问题	给定 16 个标量 (等离子体参数 + 线圈电流)，预测整个二维磁通场 $\psi(R,Z)$
数据	data_v5/dn: MAST 双零位形, 65×65 网格, 2000/500/500 样本, 训练用 N=500
训练	两阶段 PINO: 先监督拟合 ($\psi + J$), 再物理微调 (GS 残差 + l_p 约束)
结果	最优 Transformer 算子 0.635% 相对 L2 误差; X 点定位 0.42 cm

一句话结论链：纯局部卷积 (U-Net) 学不会磁面全局拓扑 → 谱域混合 (FNO) 可行 → 多尺度谱 (UFNO) 更好 → 全局注意力 (Transformer) 最好。
决定精度的不是"用不用傅里叶", 而是**全局混合机制**本身。

1. 物理问题：Grad-Shafranov 方程

1.1 托卡马克与磁通

托卡马克 (tokamak) 是一种磁约束聚变装置：用强磁场把高温等离子体"装"在真空室里。描述平衡态（等离子体静止时）磁场形状的核心方程是

Grad-Shafranov (GS) 方程：

$$\Delta^* \psi + \mu_0 R J_\phi(R, Z) = 0$$

其中：

- $\psi(R, Z)$ 是**极向磁通** (poloidal flux, 单位 Wb) ——我们要预测的场。
磁力线就是 ψ 的等值线，磁面（磁通面）的形状直接由 ψ 的等值线形状决定；
- Δ^* 是柱坐标下的"类拉普拉斯"算子
$$\Delta^* = \frac{\partial^2}{\partial R^2} - \frac{1}{R} \frac{\partial}{\partial R} + \frac{\partial^2}{\partial Z^2};$$
- J_ϕ 是环向电流密度 (单位 A/m²) ——与 ψ 通过等离子体剖面函数自洽
$$(J_\phi = R p'(\psi) + \frac{F F'(\psi)}{\mu_0 R});$$
- $\mu_0 = 4\pi \times 10^{-7}$ 是真空磁导率。

free-boundary (自由边界)：等离子体没有硬壁约束边界形状——等离子体边界 (separatrix, 分离面) 的位置和形状由**外部线圈电流**决定，而这些电流正是我们网络的输入。这是本任务与"固定边界"求解的关键区别，也是它难的地方：边界不是已知条件，是要从输入推断的输出。

出处：GS 方程见 Shafranov (1966)；入门教材：Freidberg, *Ideal Magnetohydrodynamics* (Plenum Press, 1987)。本仓库复现的 free-boundary 算子学习论文为 arXiv:2608.05555（其求解器与数据管线即 data/ 与 gs_pino 包的来源）。

1.2 任务形式化

把 GS 求解变成**算子学习** (operator learning) 问题：

$$\Psi_\theta(\mathbf{c}) \approx \psi_{\text{solution}}(\mathbf{c})$$

网络 Ψ_θ 输入 18 个通道 (§2)，输出 ψ 场 (65×65 网格)，一步到位，不迭代求解（传统的 freegs/gspack 求解器要迭代几千步）。

为什么值得做：传统求解器单次约 1 秒（CPU），深度学习前向只要 1.6 ms（GPU），快约 600 倍，可实时用于等离子体控制回路（10 kHz 级别）。

1.3 coil 分离（网络只学等离子体场）

总磁通 = 线圈产生的"真空场" + 等离子体电流产生的"等离子体场"：

$$\psi_{\text{total}} = \psi_{\text{plasma}} + \sum_{k=1}^{11} I_k G_k(R, Z)$$

其中 G_k 是第 k 个线圈的 **Green 函数**（该线圈通单位电流时产生的场，由解析公式给出，greens 恒等式验证误差 6e-8 Wb）。

为什么网络只学 ψ_{plasma} ：线圈场占 $|\psi_{\text{total}}|$ 幅值的 183%，且在线圈位置有导体奇性——若让网络直接预测总场，物理残差 $\Delta^* \psi + \mu_0 R J$ 会被线圈奇性主导，物理约束项完全失效。网络负责学"难的部分"（等离子体场），线圈部分是解析可加的。评估时再通过上式把总场加回来（实现见 [evaluate_pino.py:144-146](#)，`einsum("kij,k->ij", greens, coil_currents)` 一步加回）。

2. 数据与输入表示

2.1 数据集

字段	值
数据	data_v5/dn/train.npz 等（MAST 装置，双零位形 DN）
网格	65×65（R、Z 各 64 个间隔）
划分	2000 训练 / 500 验证 / 500 测试
本系列实验训练样本	N=500（从 2000 池 嵌套子集 抽，perm seed 12345）
参数范围	等离子体电流 Ip 0.3–0.8 MA、磁轴压强 paxis 1–5 kPa、fvac 0.3–0.8 等

嵌套子集（nested subset）：固定随机种子从全池抽 500 个，保证所有实验（N=500 vs N=2000）训练样本是包含关系，方便公平对比与后续扩量。

代码位置：数据文件 `dn_fno_2608/data_v5/dn/{train,val,test}.npz` ；
数据集与 z-score 实现见 [data_pino.py:42](#)
`DNPinoDataset` (`J` 场重构 :67、扩展统计 :82、`__getitem__` :95)；
嵌套子集抽取 `nested_train_indices` 在 [data_dn_fno.py](#)。

2.2 18 个输入通道

#	通道	含义	类型
1	R	网格径向坐标（归一化到 [-1,1]）	空间坐标场
2	Z	网格纵向坐标（[-1,1]）	空间坐标场
3	Ip	等离子体电流 (A)	标量（广播到全场）
4	paxis	磁轴压强 (Pa)	标量
5	fvac	真空通量函数 (Wb/m)	标量
6	alpha_m	剖面形状指数 m	标量
7	alpha_n	剖面形状指数 n	标量
8–17	I_P2U ... I_P6L	上下偏滤器 10 个线圈电流 (A)	标量
18	I_P1	中心螺线管电流 (A)	标量

关键设计：**不给 X 点坐标、不给位形标签**——只给可测量量（电流 + 工程参数）。位形识别（这个样本是 DN 还是 SN）是网络的隐含能力，由线圈电流模式承载（exp010/011 已证实，config 通道冗余可删）。

2.3 归一化与目标

- 输入标量 z-score 归一化（统计量来自全训练池）；
- 目标 ψ_{plasma} 与 J 也 z-score 归一化（**z 域**训练）；
- 每个样本附带**核心 mask**（等离子体内部区域二值图）—— J 在 mask 外恒为 0，物理损失只在 mask 内计算（见 §5）。

2.4 评估指标

指标	含义
rel L2	$ \hat{\psi} - \psi_{\text{true}} _2 / \psi_{\text{true}} _2$ (z 域) ——本文所有"0.635%"
GS 残差	$ \Delta^* \hat{\psi} + \mu_0 R \hat{J} $ 的 mask 内均值 (物理自洽度, 归一化 pde_scale)
Ip 相对误差	$ \sum(\hat{J} \cdot dA) - I_p / I_p$ (电流积分约束)
X 点/O 点定位误差	分离面临界点位置误差 (cm) ——磁面拓扑的指纹

3. 前置知识速成（初学者必读）

以下每个概念只讲"解决什么问题 + 一个直觉"。用到的符号： x 是输入场 (B, C, H, W)， W 是权重。

3.1 卷积与感受野

卷积：滑窗加权求和。输出每个点只看输入的一个**小邻域**（如 3×3）。
感受野（receptive field）= 输出点能"看到"的输入区域大小。堆 N 层 3×3 卷积 + 池化（下采样），感受野按指数增长，但**远距离信息要经过很多层才能传播**，且中间层会丢失细节（池化是丢信息的）。

直觉：卷积像"每个人只跟邻居商量"，全局共识要一级一级传。

3.2 傅里叶变换与谱卷积（FNO 的核心）

傅里叶变换把一张图拆成不同频率的正弦波叠加： $\mathcal{F}[x](k)$ 是频率 k 的分量（复数）。低频 $\approx$ 大尺度整体形状（磁面的大致轮廓），高频 $\approx$ 细节（X 点附近的陡峭变化）。

谱卷积：在频率域把每个模态乘一个可学习系数 $R(k)$ ，再逆变换回空间：

$$Kx = \mathcal{F}^{-1}(R(k) \cdot \mathcal{F}[x])$$

- 傅里叶变换是 $O(N \log N)$ ，而且**一次操作就让所有像素互相作用**（频域每个系数都来自全场的积分）——天然的"全局混合"；
- 只保留前 $m_1 \times m_2$ 个低频模态（截断），既减少参数又是隐式的平滑先验（高频细节被砍掉）——FNO 的"模态数"就是这个截断数。

直觉：谱卷积像"开全员大会"——一次 FFT 就汇总了所有人的意见，按频率分配权重（低频权重给大局观，高频给细节）。

3.3 MLP（多层感知机）

$h = W_2 \sigma(W_1 x + b_1) + b_2$ ：逐点（per-pixel）的线性变换 + 非线性激活。MLP **没有空间结构概念**——它对每个像素独立处理，除非把 (R,Z) 坐标作为输入喂给它（DeepONet trunk 就是这么做的）。

3.4 Transformer 自注意力（Transformer 算子的核心）

自注意力让序列里每个 token 与**所有其他 token** 交互，权重由内容决定：

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right) V$$

- Q（查询）、K（键）、V（值）由输入线性投影而来；
- $QK^\top$ 是"每对 token 的相关性"矩阵（注意力权重）；softmax 归一化成概率；加权求和 V 得到新表示；
- 与谱卷积对比：谱卷积的混合权重 $R(k)$ 是**固定模态**的（所有样本共用），注意力权重是**内容自适应**的（每个样本、每对 token 单独算）——更灵活，但代价是二次复杂度 $O(N^2)$ （N 是 token 数），所以 $65 \times 65 = 4225$ 像素直接做注意力不可行，要先降采样成 $32 \times 32 = 1024$ 个 token (§4.7)。

3.5 SVD 与 POD（POD-DeepONet 的核心）

SVD 把矩阵 $X = U \Sigma V^\top$ 分解。对"样本 $\times$ 像素"的矩阵做 SVD，右奇异向量 V 的前 p 行就是数据的主导**模式**（主成分/POD 基）：第一个模式抓住最大的变化方向，后面的逐次抓住剩余的最大方向。累计能量

$$E_p = \frac{\sum_{k=1}^p \sigma_k^2}{\sum_k \sigma_k^2}$$

告诉你有多少变化被前 p 个模式覆盖。POD-DeepONet 的整个想法：既然 ψ 解空间可能低维，干脆用数据算出的前 p 个模式当"底座"，网络只学每个样本的**系数** (§4.6)。

3.6 B-spline 基函数（KAN 的核心）

KAN（Kolmogorov-Arnold Networks）把神经元的"固定激活"换成**可学习的样条函数**：每个连接一个一维函数

$$\phi(x) = w_b \text{silu}(x) + w_s \sum_b c_b B_b(x)$$

$B_b(x)$ 是 $[-1,1]$ 上均匀结 (knot) 的分段多项式基 (B-spline)，系数 c_b 可学习——网络能学出任意的单变量函数形状 (而 ReLU/GELU 是固定的)。参数多 (每个连接要学基系数)，但理论上表达力强。

4. 架构家族

所有架构共享统一接口 `forward(x: (B,18,65,65)) -> (B,2,65,65)` (通道 0 = ψ_{plasma} , 通道 1 = J)，通过 `MODEL_REGISTRY` 注册表接入训练管线，参数量按“复数参数计 1 个”的约定统计。**两阶段训练方案对所有架构完全相同**，所以架构对比是干净的 (只变 `--model` 一个参数)。

4.1 FNO2d2608 (基线, exp102)

```

x (18×65²)
  | Conv2d 1×1 (lift, 18→64)
  ▼
[FNOBlock × 4] —每个块→ SpectralConv2dR (谱卷积, 16×16 模态, 64→64)
  |                       + Conv2d 1×1 (逐点混合, 64→64)
  |                       → GELU
  ▼
Conv2d 1×1 (proj, 64→2)
y (2×65²)

```

数学：每个 FNOBlock 是

$$h_{\ell+1} = \sigma\left(\mathcal{F}^{-1}[R_{\ell}(k) \mathcal{F}[h_{\ell}]] + W_{\ell} h_{\ell}\right)$$

谱部分做全局混合 (§3.2)， 1×1 卷积做逐点通道混合，GELU 是激活。

关键代码：[model_dn_fno.py](#) 的

`SpectralConv2dR` / `FNOBlock`。`SpectralConv2dR.forward` 里 `torch.fft.rfft2` → 只保留前 16×16 模态做复数乘法 (`einsum "bixy,ioxy->boxy"`) → `torch.fft.irfft2` 还原。

参数：约 4.21M (18 通道输入版，论文 9 通道口径 4,770,241)。


结果：exp102 两阶段 test rel L2 **0.800%**，lp 误差 0.21%，mask 内 J 1.36%。单阶段做法（exp101，物理残差用数据 RHS）0.72%。

为什么它有效：椭圆方程（GS）的解具有"全局耦合"性质——任何一点的 ψ 由全场边界条件共同决定。FFT 一次操作实现全局混合，恰好匹配这个性质。

位置与参考

项	位置
源码	model_dn_fno.py:73 FNO2d2608 （谱核 SpectralConv2dR :27、 FNOBlock :61、 build_model :99）
实验	exp102_pino_twostage_n500/ （两阶段基线 0.800%）；单阶段对照 exp101_pino_rhs_n500/
脚本	run_exp101_102_pino.sh
参考	Li et al., "Fourier Neural Operator for Parametric Partial Differential Equations", ICLR 2021 (arXiv:2010.08895)

4.2 U-Net（纯卷积，exp301，失败）



思想：编码器逐级下采样（信息压缩），解码器逐级上采样（细节恢复），skip 连接把每级的空间细节直接送到对应解码级。CNN 的经典骨架。

关键代码：[models_alt.py](#) 的 UNet2d2608 （2.76M 参数）。注意 `F.interpolate(size=...)` 用显式 size 而非 `scale_factor`——65 不是 2 的幂，`scale_factor` 会取整错位。

结果：exp301 **2.202%**——FNO 的 2.75 倍。阶段1 卡在 3.017%（差 0.017 点达不到 3% 阈值，e300 兜底切换），X 点定位 1.83/2.32 cm（FNO 的 3-4 倍），GS 残差 4.3 倍。所有"全局"指标同步退化。

为什么失败（这是全系列最重要的对照）：磁面拓扑（X 点位置、分离面形状）由远处线圈电流 + 参数全局决定，3×3 卷积的感受野要堆十几层才够远，而且池化把细节丢了。**局部感受野不足承载磁面全局耦合。**文献里 "CNN 在 GS 任务上最佳平衡"的结论在这里不迁移——因为该基准没有物理约束项且是单阶段。

位置与参考

项	位置
源码	models_alt.py:140 UNet2d2608 （_DoubleConv :87、_UpBlock :103、构造器 _build_unet2d2608 :181）
实验	exp301_unet_pino_twostage_n500/ （2.202% 失败归因）
脚本	run_exp301_302_pino.sh
参考	Ronneberger et al., "U-Net: Convolutional Networks for Biomedical Image Segmentation", MICCAI 2015（arXiv:1505.04597）；EXL-50U 五架构基准（arXiv:2608.23217，见 ARCHS_SURVEY.md §3 ）

4.3 UFNO（多尺度谱 U-Net，exp302）

思想：U-Net 的编码器各层换成 FNOBlock，模态数随分辨率收缩——

- 65²：FNOBlock 16×16 ← 高分辨率谱核：保细节
- 32²：FNOBlock 16×16
- 16²：FNOBlock 8×8 ← 低分辨率谱核：承载全局
- 8²：FNOBlock 4×4

解码器用普通卷积上采样 + skip。

关键代码：[models_alt.py](#) 的 UFNO2d2608 （2.47M = FNO 的 0.59×）。谱核 FNOBlock(w, m1, m2) 的模态数 (m1,m2) 随层深度递减，与分辨率匹配。

结果：exp302 **0.729%**（FNO -9%），J mask 1.13%（-17%），X 点 0.52/0.63 cm。**全面小幅击败 FNO 且参数更少。**exp305 调优版（解码器也谱

化 + bottleneck ×2 + 模态 16→20) 进一步到 0.7147%，主要收益是阶段1 收敛翻倍 (e70→e30)。

为什么有效：多尺度 = "高分辨率层保细节 + 低分辨率层承载全局"两个能力解耦，比 FNO 单分辨率（16×16 模态一律作用于 65²）更细粒度。

位置与参考

项	位置
源码	models_alt.py:191 UFN02d2608 （构造器 <code>_build_ufno2d2608</code> :246、调优版 <code>_build_ufno2d2608_tuned</code> :252）；仓库另有论文风格遗留实现 UFN02d / UFN02d_v2 （ models.py:330-380 ，仅参考未用）
实验	exp302: exp302_ufno_pino_twostage_n500/ ；调优 exp305: exp305_ufno_tuned_pino_twostage_n500/ ；训练侧负收益 exp306: exp306_ufno_weights_pino_twostage_n500/
脚本	run_exp301_302_pino.sh (exp302)； run_exp305_306_pino.sh (exp305/306)
参考	Wen et al., "U-FNO — An Enhanced Fourier Neural Operator-based Deep-learning Model for Multiphase Flow", Adv. Water Resour. 2022 (arXiv:2109.03697)

4.4 FNO-KAN（exp303，中性结果）

思想（来自 KANO 论文论点）：GS 是**变系数**方程（系数里含 R），固定形状的激活可能表达力不足，逐点换成可学习激活（KAN）能补上。做法：FNO 骨架不变，把 FNOBlock 里的 1×1 卷积换成 **KANConv1x1**（逐像素 B-spline）：

$$h_{\ell+1} = \sigma\left(\mathcal{F}^{-1}[R_{\ell}(k)\mathcal{F}[h_{\ell}]] + \text{KAN}_{1\times 1}(h_{\ell})\right)$$

关键代码：[models_alt.py](#) 的 KANConv1x1 （4.33M 参数，+3%）。三个工程细节：

- 1. **tanh 门控：**B-spline 基定义在 [-1,1]，而谱卷积输出无界——先 tanh 压缩进样条域；
- 2. **融合矩阵乘法：** `h = silu(x)@wb + B(x)@(Ws*C)` 一次矩阵乘法算完，绝不物化 (B, N, C_in, C_out) 的中间张量（会爆显存）；
- 3. **基函数在 no_grad 下计算：**B-spline 基只依赖输入 x 和固定网格，梯度只流向系数——省一半反向图，基的梯度路径本来就很小。

结果：exp303 **0.857%**——机制成立（收敛正常、无 NaN）但**增益为零**
（全部指标与 FNO 差 $\leq 0.1pp$ ），代价是 4× 训练时长。KANO"变系数需可学习激活"的论点在 $65^2 \times 16 \times 16$ 模态下未转化：R 因子的变化已经被谱核充分捕获。

与点式 KAN (§4.8, 20.87% 失败) 合起来是一个完整证据链：**KAN 可以工作（插进 FNO 无损伤），但不更好**——瓶颈不在激活形状。

位置与参考

项	位置
源码	models_alt.py:270 KANConv1x1 （批量 B-spline 递归 <code>_bspline_bases_batched</code> :46）；FNOKAN2d2608 :318、块 <code>_FNOKANBlock</code> :342、构造器 :355；B-spline 基函数从 model_kan.py:38-114 复用
实验	exp303_fnokan_pino_twostage_n500/ (0.857% 中性结果)
脚本	run_exp303_304_pino.sh
参考	Liu et al., "KAN: Kolmogorov-Arnold Networks", ICLR 2025 (arXiv:2404.19756)；KANO 算子版 (arXiv:2407.04192)

4.5 PI-DeepONet（exp304，容量奇迹）

思想：DeepONet 把"参数 $\rightarrow$ 场"映射拆成两个 MLP 的内积：

$$\psi(R, Z) = \sum_{k=1}^p b_k(\underbrace{I_p, p_{\text{axis}}, \dots, I_{P1}}_{16 \text{ 个标量}}) \tau_k(R, Z)$$

- **branch 网络：**16 个标量 $\rightarrow$ p=256 维系数向量；
- **trunk 网络：**(R,Z) 坐标 $\rightarrow$ 256 维基函数向量（学习的主干）；
- 输出 = 逐像素内积（`einsum "bp,bnp->bn"`）。

这就是"分支-主干分解"：标量输入 $\rightarrow$ 场输出问题的最直接结构（本问题与 DeepONet 的设定精确同构）。 ψ 和 J 各一个 branch（J 是 ψ 的二阶导场，单独建模更准）。

关键代码：[models_alt.py](#) 的

PIDeepONet2d。两个细节：trunk 末层权重 $\times 0.1$ （输出从小起步，避免初始 MSE 巨大）；branch 输入 = `x[:,2:].mean((2,3))`（标量通道是广播常数，空间平均无损还原）。

结果：exp304 **0.802%**——0.6M 参数（FNO 的 1/7）达到与 FNO 统计上不可区分的精度，训练最快（~20 min）。但 J mask 2.61%、Ip 0.384%（FNO 的约 1.8-2 倍）——**容量分配：**参数都被 ψ 主任务吃掉，J（二阶导场）被饿着。exp307 把宽度 256→384（1.34M）验证了这个诊断：**0.7575%、Ip 0.210%（-45%，反超 UFNO）、J 2.13%**——加宽就修好了。

位置与参考

项	位置
源码	models_alt.py:381 PIDEepONet2d（_MLP :366、构造器 :438、加宽版 _build_pideeponet2d_wide :444、傅里叶特征版 _build_pideeponet2d_ff :453）；仓库论文风格 PlaNet 系另有遗留（ models.py:199-275 ，仅参考未用）
实验	exp304: exp304_pideeponet_pino_twostage_n500/ （容量奇迹）；加宽 exp307: exp307_pideeponet_wide_pino_twostage_n500/ ；FF 失败 exp308: exp308_pideeponet_ff_pino_twostage_n500/
脚本	run_exp303_304_pino.sh （exp304）； run_exp307_308_pino.sh （exp307/308）
参考	Lu et al., "Learning nonlinear operators via DeepONet...", Nature Machine Intelligence 3, 2021（arXiv:1910.03193）；SUNIST-2 物理约束 DeepONet 部署（调研见 ARCHS_SURVEY.md §3.3 ）

4.6 POD-DeepONet（exp312，诚实负面）

思想（与 DeepONet 只差一半）：回顾 §4.5——DeepONet 的两半都是学出来的：branch 学"这个样本的系数"，trunk 学"每个位置的基"。POD-DeepONet 的关键发问：**trunk 的 256 个基函数，为什么不直接用统计方法从数据里算出最优的那几个？**于是把学习 trunk 换成**数据算出的固定 POD 基**：

$$\psi_z(R, Z) = \psi_0(R, Z) + \sum_{k=1}^p b_k \phi_k(R, Z)$$

- ψ_0 ：训练样本的平均场； $\{\phi_k\}$ ：样本快照矩阵的 SVD 右奇异向量（前 p 个，§3.5）；
- 基是固定 buffer（register_buffer，**无梯度**），阶段2 物理微调只能动系数 b_k ——**低秩先验即实验假说**：若解的线性子空间足够，系数微调应达到学习 trunk 同档精度。

SVD 怎么算的（具体数字）：把 $N=500$ 训练子集的 ψ 场排成

500×4225 矩阵（500 样本 $\times$ 65×65 像素），减去平均场后

`np.linalg.svd(X, full_matrices=False)` 得到 V^T (4225×4225 的行是模式)，

取前 p 行当基。注意**两个细节**（都踩过坑）：

① 基必须来自**嵌套训练子集**而不是全池（`idx = ds.indices`，[train_pino.py:55](#)）——否则基和训练目标不同分布；

② 快照用 **z 域**（与网络训练目标一致，`pod_basis_from_dataset` 内部做了 z-score），不是物理域。

p 怎么定：能量判据，不是调参。 累计能量

$$E_p = \frac{\sum_{k=1}^p \sigma_k^2}{\sum_k \sigma_k^2}, \quad p = \min\{p : E_p \geq 0.999\}$$

按顺序累加奇异值平方占比，到 99.9% 就停（封顶 256 模态）。 p 是**数据结构的自动读数**，这正是本实验的巧妙处——它在回答"这个数据集本质上需要多少个自由度"：

- $p_\psi = 3$ （能量 99.924%）—— ψ 解空间惊人地低秩；
- $p_j = 10$ （能量 99.926%）—— J 是 ψ 的二阶导场，低秩性弱约 3 倍。

为什么会得到 $p_\psi=3$ （物理直觉）：

1. **coil 分离**：线圈场被解析减掉，网络只学等离子体场——其形状自由度本来就少（真空场才是 11 维电流张出的）；
2. **椭圆方程解光滑**：GS 是椭圆型方程，解没有锐利结构，跨样本变化由几个大尺度方向主导（如整体幅值档位、上下不对称度、形状偏心率——SVD 是纯统计分解，不保证每个模式有干净的名字，但量级就是"极少模式覆盖绝大多数变化"）；
3. **采样结构**：5 个标量参数 + 11 个电流在该解流形上张出的主导方向只有 3 个。

网络只剩 branch：16 标量 $\rightarrow$ 256×3 层 MLP $\rightarrow$ 13 个系数（ ψ 的 $3 + J$ 的 10），前向一步矩阵乘法 $\psi = \psi_0 + \text{branch}(x) @ \phi$ ，全部 **0.28M 参数**（系列最小，exp307 的 $0.21 \times$ ）。训练 3.7 min（分支 13 系数，800 epoch 上限远未用满）。

结果：exp312 **1.508%**（exp307 的 2 倍），X 点 0.85/0.85 cm (+0.26)，O 点 0.65 cm (+0.45)，J 2.52%，Ip 0.253%（物理约束在低秩空间仍有效）。

为什么失败：能量 $\neq$ 精度（这个负面结果最有信息量）：

1. **SVD 按方差排序，不按物理重要性排序。**截断掉的 0.08% 能量恰是 **X 点尺度的结构**——X 点附近陡峭变化占总方差极小（几个像素），但对磁面拓扑是决定性的。证据：误差集中在被截断的模式上（X 点 0.85 vs 0.59 cm、O 点 0.65 vs 0.20 cm）。能量判据（0.999）与精度判据（0.7% 档）是两把不同的尺子；
2. **线性子空间的边界：**预测 ψ 被锁死在 3 个模式的线性组合里；而 exp307 的学习 trunk 能让"基形状"随输入连续变化——本质上学习的是 **非线性、自适应的基** $\approx$ "自适应非线性 POD"。它超出线性子空间的 0.7pp 就是非线性表达的价值；
3. 结论：**"数据低秩 $\Rightarrow$ 线性基够用"被否定**——低秩是数据的统计性质，不是解的完整描述。 $p_{\psi}=3$ 本身是数据集结构诊断：v5/dn 的参数化采样在冗余维度上不会增加网络需学的模式（对未来数据增强/参数采样设计有直接意义）。

什么时候 POD 反而有用（文献视角）：POD-DeepONet (Lu et al. 2022) 原文的卖点是**噪声鲁棒性**——固定基 = 强正则化，含噪数据下线性基天然滤噪。本实验是干净数据 + 高精度要求，正则化变成瓶颈。未来若遇高噪声数据（实验测量），POD 基可能反超。

"POD 基 + 学习残差"双通道已在 exp313 落地：本节的诊断（基管大体形状、网络补 X 点细节）正是 exp313 的设计蓝本——低秩 POD 通道原样保留，并联小 FNO 残差学 $y - \psi_{\text{pod}}$ （分阶段冻结协议先 branch 后残差，消除通道竞争）：**1.508% $\rightarrow$ 0.883% (-41%)**，X 点 0.85 $\rightarrow$ 0.54/0.56 cm、O 点 0.65 $\rightarrow$ 0.34 cm、GS 残差 -73%——被截断的 0.08% 能量确实是 X 点尺度结构，且谱卷积残差能把它学回来。870K 参数（FNO 的 0.21 $\times$ ）达到 FNO 的 $\sim$ 90% 精度（median 持平 0.645 vs 0.642，X 点反超）；代价是 l_p 略退化（0.253% $\rightarrow$ 0.338%：残差放大 J 自由度，分布更准但积分匹配略松）。详见 [exp313 README](#)。

残差通道需要多少全局性？（exp314 消融，残差换成纯卷积 UNet）——POD 基承担全局形状后，基外细节**部分**需要全局混合：纯卷积残差把 POD 从 1.508% 拉到 1.099%（-27%：X 点 -25%、O 点 -44%、GS 残差 -62%），但明显弱于 FNO 残差（+0.22pp）——完整任务下纯卷积 = FNO 的 2.75 $\times$ 差距，残差任务下缩小到 $\sim$ 1.25 $\times$ ，谱混合仍提供 X 点 -0.1 cm 级别的边际增益。详见 [exp314 README](#)。

位置与参考

项	位置
源码	models_alt.py:550 pod_basis_from_snapshots (SVD + 能量判据); PODDeepONet2d :581、构造器 :629; exp313 PODResidual2d2608 :641 (POD 通道 + FNO 残差 + 冻结接口 set_branch_frozen / set_residual_frozen); 训练侧基计算 pod_basis_from_dataset (train_pino.py:55 , 注意基必须来自嵌套子集 ds.indices); 冻结协议 --pod-pretrain-epochs (train_pino.py:151 , 交接 :290、阶段1 挂起 :299)
实验	exp312_pod_deeponet_pino_twostage_n500/ (1.508% 诚实负面 + 能量诊断); exp313_pod_residual_pino_twostage_n500/ (0.883%, 双通道分工 + 冻结协议); exp314_pod_residual_unet_pino_twostage_n500/ (1.099%, UNet 残差消融——基外细节部分需要全局混合)
脚本	run_exp311_312_pino.sh (exp312); run_exp313_pino.sh (exp313); run_exp314_pino.sh (exp314, 均 --pod-pretrain-epochs 60)
参考	Lu et al., "A comprehensive and fair comparison of two neural operators...", 2022 (arXiv:2304.00643, POD-DeepONet)

4.7 Transformer 算子（TKNO-lite，exp311，系列最优）

思想：这个架构的实质是一个 **conv-stem Transformer**——卷积主干保全分辨率细节 + 全局自注意力做混合。它来自 TKNO（Transformer-KAN Neural Operator，[arXiv:2511.19114](#)——在同

一个 GS 任务（EXL-50U，五架构基准）上胜出，监督 0.25%），但按 exp303 证据**剥离了 KAN**（逐点 KAN 增益 ≈ 0 ）。所以实现里**没有 KAN**，本质就是纯 Transformer；"TKNO-lite"只是实验代号（lites = 去掉 KAN 的 TKNO）。

结构：

```

x (18×652)
| Conv3×3 (stem, 18→64) + GELU      ← 652 细节路径
▼
stem (64×652)
| Conv4×4/s2 (patch embed, 64→128) + 位置编码
▼
tokens (128×322 = 1024 token)
| [TransformerBlock × 4] —每个块→ LayerNorm → 8头自注意力
|                               LayerNorm → MLP(GELU, 4×宽)
▼
bilinear 上采样 (size=652, 显式)
| 与 stem 拼接 (128+64 → 64, DoubleConv)
▼
Conv1×1 → y (2×652)

```

几个设计决策（都有明确理由）：

- **为什么 32²=1024 token**：65²=4225 直接自注意力是 $O(N^2)$ ，batch 16 下不可行；1024 是 8 的倍数，能走 fused SDPA 快速路径（33²=1089 会退化）；
- **为什么保留 conv stem 的 65² skip**：patch 降采样会丢 X 点尺度的细节，用 stem 的原始分辨率做 skip 拼接补回（跟 U-Net 一个道理）；
- **位置编码**：注意力本身对 token 顺序不敏感，加可学习的 2D 位置编码告诉它“这是哪个网格位置”；
- **need_weights=False**：默认会物化 (B, heads, N, N) 注意力矩阵（4.6 GiB），关闭后走 fused SDPA（0.92 GiB）。

结果：exp311 **0.635%**——系列新纪录（比上一位 exp305 低 11%），且只有 1.21M 参数（FNO 的 0.29×）。全指标最佳：J mask 0.977%（UFNO -14%）、lp 0.189%、X 点 0.42/0.43 cm、O 点 0.18 cm。代价：训练 80 min（本 torch 构建无 flash 注意力，走 mem-efficient 后端，是 FNO 的 5.2×）——纯时间代价，不改变结论。

为什么它最强：与 exp301（UNet 失败）/exp302（谱系成功）对照——**磁面全局耦合的决定变量是混合的全局性，不是具体实现**。注意力的内容自适应混合比谱卷积的固定模态混合更贴合局部结构（J 的 -14% 就是证据：J 是二阶导场，对细节敏感）。

位置与参考

项	位置
源码	models_alt.py:491 TKNOLite2d2608 (块 <code>_TransformerBlock</code> :467、构造器 <code>_build_tkno_lite</code> :539); 代码注册表键名 <code>tkno_lite</code> (models_alt.py:654)
实验	exp311_tkno_lite_pino_twostage_n500/ (0.635% 系列最优)
脚本	run_exp311_312_pino.sh
参考	TKNO (Transformer-KAN Neural Operator), ICML 2026 (arXiv:2511.19114, 同一 GS 任务五架构基准胜出); Vaswani et al., "Attention Is All You Need", NeurIPS 2017 (arXiv:1706.03762)

4.8 点式 KAN (kan 轨，20.87% 失败，对照)

独立实验轨 (`gs_pino_kan_2608`): 论文口径的纯逐点 KAN (19 通道 $\rightarrow$ 10 $\rightarrow$ 2, 每连接一个 B-spline 函数)。

结果: 20.87%——两个原因叠加: ① 只有 1,260 参数 (容量不足); ② **逐点结构没有空间混合**——每个 (R,Z) 像素只看到自己的输入, 磁面全局耦合完全无从谈起。这是"架构对比"系列没做之前就得到的教训, 也是 FNO-KAN (§4.4) 要保留谱卷积的原因。

位置与参考

项	位置
源码	model_kan.py:197 BSplineKAN (<code>KANLayer</code> :135、 <code>_knots</code> :38、 <code>_bspline_bases</code> :47、解析二阶导 <code>forward_with_derivs</code> :223、剪枝 :242); 训练脚本 train_kan.py 、评估 evaluate_kan.py
实验	kan/experiments/exp001_kan_v5/model_b19ch_kan_mix (20.87% 失败)
脚本	见 train_kan.py:38 用法示例
参考	"基于 Kolmogorov-Arnold Networks 的 Grad-Shafranov 方程自由边界问题求解方法", Acta Phys. Sin. 75(2026)150504, DOI 10.7498/aps.75.20260331 (逐点 KAN 原文, 本轨复现)

4.9 参数-精度全景

架构	参数	test rel L2	一句话
点式 KAN	1.3k	20.87%	容量 + 无全局混合，双败
U-Net	2.76M	2.202%	纯局部卷积，全局耦合学不会
POD-DeepONet	0.28M	1.508%	低秩先验过度激进
FNO	4.21M	0.800%	基线：谱卷积全局混合
PI-DeepONet	0.60M	0.802%	容量奇迹，J/lp 通道饿着
FNO-KAN	4.33M	0.857%	KAN 可工作但不更好
DeepONet wide	1.34M	0.7575%	加宽修复 J/lp 短板
UFNO	2.47M	0.729%	多尺度谱，参数只有 FNO 0.59×
UFNO tuned	3.60M	0.7147%	解码器谱化，边际小胜
Transformer (TKNO-lite)	1.21M	0.635%	全局注意力，系列最优

5. 两阶段 PINO 训练方法

训练方法代码地图 (§5 全程对应)：

内容	位置
两阶段主循环 (stage/ramp/损失组合)	train_pino.py:218-315
阶段切换判据	train_pino.py:277-282
物理损失实现 (Δ^* 、残差、lp)	losses_pino.py:37-78 (<code>lap_star_torch</code> :37、 <code>pde_residual_rhs</code> :48、 <code>pde_residual_self</code> :60、 <code>ip_constraint</code> :71)
模型注册表/统一接口	models_alt.py:640-661 (<code>MODEL_REGISTRY</code> + <code>build_model</code>)
训练入口/超参	train_pino.py:111-151

内容	位置
评估与 coil 分离加回	evaluate_pino.py:57-201 (load_checkpoint :57、psi_total 重建 :144)

5.1 为什么纯监督不够？

纯 MSE 训练（exp011）只能学到“数据里有的”：

- 它学不到 **psi↔J 自治**：数据里的 J 是求解器算出来冻着的，ψ 和 J 的关系不会被监督强化，预测对组合可能物理不自洽；
- 它学不到 **Ip 约束**：J 场积分等于等离子体电流——数据里有这个信息，但网络不会自动尊重积分守恒。

物理损失（PINO，Physics-Informed Neural Operator）把 GS 方程本身写进损失函数，让网络学会“满足方程”——**纯数据管线拿不到的自治性与积分约束，物理损失提供**（exp101/102 的直接证据：Ip 误差 0.21%，mask 内 J 1.36%）。

5.2 两阶段损失（做法2，exp102 起）

阶段 1（监督拟合）——先把场拟合好：

$$L_1 = \underbrace{\text{MSE}(\hat{\psi}_z, \psi_z)}_{\psi \text{ 主任务}} + w_j \cdot \underbrace{\text{masked MSE}(\hat{J}_z, J_z)}_{\text{core mask 内}}$$

阶段 2（物理微调）——在 L1 上追加自治残差与 Ip 约束：

$$L_2 = L_1 + \lambda(t) \left[\underbrace{w_{\text{pde}} \left\| \frac{\Delta^* \hat{\psi} + \mu_0 R \hat{J}}{\text{pde_scale}} \right\|_{\text{mask 内}}^2}_{\text{GS 自治残差（用网络自己的 J）}} + \underbrace{w_{\text{ip}} \left\| \frac{\sum \hat{J} dA - I_p}{\text{ip_scale}} \right\|^2}_{\text{等离子体电流积分约束}} \right]$$

要点：

1. **自治残差用的是网络自己的 J**（pde_residual_self），不是数据 RHS——这迫使 ψ 与 J 互相一致（做法1/exp101 用数据 J 当 RHS，只能做输出侧平滑，给不了自治）；
2. **mask 内**：残差只在等离子体核心区内算（mask 外 J 恒为 0，二阶差分会有谱振铃假象）；
3. **pde_scale / ip_scale 归一化**：把不同物理量纲的项拉到 O(1)（0.362 Wb/m²、5.51e5 A），否则数值上没法平衡权重；

- 4. 权重: $w_{pde} = 0.1, w_{ip} = 1.0, w_j = 1.0$ (exp306 实验证明这组已经吃满杠杆, 加大反而挤压 ψ 主任务);
- 5. $\lambda(t)$ 是 warm-up ramp: 见下。

5.3 为什么必须有 warm-up ramp? (踩过的坑)

阶段切换的瞬间, $\psi \leftrightarrow J$ 自治尚未建立: J 只是监督拟合的, $\Delta^* \psi + \mu_0 R J$ 残差很大。若物理权重直接全量上 ($\lambda=1$), 巨大的物理梯度会把阶段1 辛苦拟合的 ψ 场摧毁——第一版实现 (v6) 阶段2 首 epoch 直接爆炸。

修复: 物理权重从 0 线性预热 30 个 epoch ($ramp = \min(1, (epoch - switch)/30)$) ——给网络一个"过渡期", 在残差还很大的时候物理项只轻轻推, 等 $\psi \leftrightarrow J$ 开始自治了再全力拉。

5.4 阶段切换判据

stage 1 $\rightarrow$ stage 2 : $val\ rel\ L2 < 3\%$ 或 $epoch \geq 300$

先达标者触发 (300 是兜底)。各架构切换时机: FNO e29、DeepONet e42、UFNO e70 (调优版 e30)、Transformer e66、POD e16 (线性基起步最快)。

5.5 物理残差的计算细节

lap_star_torch 用二阶中心差分在 interior (63×63) 网格上离散 Δ^* :

$$\frac{\partial^2 \psi}{\partial R^2} \approx \frac{\psi_{i+1,j} - 2\psi_{i,j} + \psi_{i-1,j}}{dR^2}, \quad \frac{\partial \psi}{\partial R} \approx \frac{\psi_{i+1,j} - \psi_{i-1,j}}{2\,dR}$$

R_c 取 interior 网格的物理 R 值 (防除零加 $1e-8$)。J 场的预测在物理域 (反 z-score) 参与残差——物理损失永远作用在物理量上 (Wb 、 A/m^2), 监督项留在 z 域。

5.6 完整训练超参

超参	值	说明
优化器	AdamW lr 1e-3, wd 1e-4	
调度器	ReduceLROnPlateau (patience 20, factor 0.5, min_lr 1e-5)	按 val rel L2

超参	值	说明
batch / epochs	16 / 800	
早停	patience 75， 仅阶段2 起计	阶段1 不早停
权重	w_pde=0.1, w_ip=1.0, w_j=1.0, ramp 30 epochs	§5.2
阶段1	阈值 3% / 兜底 300 epochs	§5.4
随机性	seed 1（训练）、perm_seed 12345（子集抽取）	全系列固定， 保证可比

phase-aware best: 阶段1 与阶段2 各记一个最佳 val 权重存档，artifact 优先取阶段2 best（阶段2 一旦开始，阶段1 的模型不算数）。

5.7 训练循环伪代码

```
for epoch in 1..800:
    stage = 1 if switch_epoch is None else 2
    ramp = min(1, (epoch - switch_epoch) / 30) if stage == 2 else 0
    for batch:
        pred = model(x)
        loss = MSE(psi_z) + w_j * maskedMSE(J_z)           # 阶段1 一直有
        if stage == 2:
            loss += ramp * (w_pde * pde_residual_self(ψ, J, mask)
                           + w_ip * ip_constraint(J, mask, Ip))
        loss.backward(); optimizer.step()
    if stage==1 and (val_rel_l2 < 3% or epoch == 300):
        switch_epoch = epoch                               # 进入阶段2
    if stage==2 and no improvement for 75 epochs:
        early stop
```

6. 结果全景与结论链

6.1 总结果表（test n=500，data_v5/dn）

实验	架构	rel L2 total	J mask	lp	X 点 (cm)
exp301	U-Net	2.202%	3.86%	0.587%	1.83/2.32
exp312	POD-DeepONet	1.508%	2.52%	0.253%	0.85/0.85
exp314	POD 基 + UNet 残差	1.099%	2.33%	0.403%	0.64/0.64
exp313	POD 基 + 小 FNO 残差	0.883%	1.76%	0.338%	0.54/0.56
exp102	FNO	0.800%	1.36%	0.21%	—
exp304	PI-DeepONet	0.802%	2.61%	0.384%	0.73/0.70
exp303	FNO-KAN	0.857%	1.45%	0.238%	0.67/0.71
exp306	UFNO 训练调优	0.7794%	1.14%	0.240%	—
exp307	DeepONet wide	0.7575%	2.13%	0.210%	0.59/0.51
exp302	UFNO	0.729%	1.13%	0.213%	0.52/0.63
exp305	UFNO tuned	0.7147%	1.20%	0.182%	0.63/0.61
exp311	Transformer（TKNO-lite）	0.635%	0.977%	0.189%	0.42/0.43

（X 点列缺失 = 该实验未报；完整每桶数据见各实验 README 与 [EXPERIMENTS.md](#)。）

6.2 结论链（按证据顺序）

1. 纯局部卷积失败（exp301 vs exp102）：U-Net 2.202% = FNO 的 2.75×，全局指标（X 点、GS 残差、J）同步退化 → 局部感受野不足承载磁面全局拓扑。文献"CNN 最佳"结论不迁移（该基准无物理约束/单阶段）。
2. 全局混合是决定变量，不是傅里叶（exp301/302/311 三件套）：谱卷积（FNO/UFNO）与全局注意力（Transformer）都成功、纯局部都失败 → "混合的全局性"才是决定因素；注意力甚至优于谱（内容自适应 vs 固定模态）。Transformer 算子 0.635%（exp311）是当前系列最优。
3. 多尺度谱 > 单尺度谱（exp302 vs exp102）：高分辨率保细节 + 低分辨率承载全局的解耦，参数还少 41%。

4. **KAN 可工作但不更好** (exp303 + 点式 KAN 轨)：插进 FNO 增益 ≈ 0 (变系数论点被谱核吸收)，逐点 KAN 双败 (容量 + 无全局)。结论：别为 KAN 付 $4\times$ 训练时间。
5. **分支-主干分解是最经济的局部解** (exp304/307)：0.6M 参数追平 4.2M FNO，加宽到 1.34M 反超 (0.7575%)；J/lp 短板是容量分配问题，加宽即愈。
6. **低秩先验单独封顶，但可修复** (exp312 $\rightarrow$ exp313/314)：p_psi=3 (99.92% 能量) 封顶 1.5%；能量判据 $\neq$ 精度判据；p_psi=3 是数据集结构诊断 (v5/dn 解空间极低秩)。**并联残差通道直接修复**：小 FNO 残差 (exp313) 1.508% $\rightarrow$ 0.883% (-41%)、X 点 0.85 $\rightarrow$ 0.54/0.56 cm、O 点 0.65 $\rightarrow$ 0.34 cm——被截断的 0.08% 能量确实是 X 点尺度结构；870K 参数 (FNO 的 0.21 $\times$) 达 FNO $\sim$ 90% 精度。**残差架构消融 (exp314)**：纯卷积 UNet 残差 1.099% (-27%，弱 0.22pp) ——基外细节"部分需要"全局混合 (完整任务 2.75 $\times$ $\rightarrow$ 残差任务 1.25 $\times$ 差距)，谱混合仍是最优残差。分工靠分阶段冻结协议 (先 branch 60 epochs 后残差)，消除双通道竞争。
7. **物理损失的价值** (exp101/102 系列)：自治 + lp 约束是纯监督给不了的；物理权重必须 warm-up (λ 从 0 线性爬升 30 epochs)，否则阶段2 首 epoch 爆炸。

6.3 已知失败方向（省钱清单）

方向	实验	结论
损失权重加大	exp306	杠杆已吃满，加大负收益
trunk 傅里叶特征	exp308	高频注入被二阶差分放大，梯度风暴（机制性不兼容）
POD 低秩基 (独立)	exp312	3 模态封顶 1.5%，线性子空间装不下 X 点细节； 混合路线可行 (exp313：并联 FNO 残差 $\rightarrow$ 0.883%)
点式 KAN	kan 轨	1.3k 参数 + 无全局混合，20.87%
FNO-KAN	exp303	机制成立、增益零、 $4\times$ 时间

7. 复现指南

```
# 两阶段训练 + 评估 (exp311 Transformer / exp312 POD-DeepONet)
bash dn_fno_2608/scripts/run_exp311_312_pino.sh all

# 任意架构 (注册表内: fno2d2608 / unet / ufno / ufno_tuned / fnokan /
#               deeponet / deeponet_wide / deeponet_ff / tkno_lite / pod_deeponet)
cd "$(git rev-parse --show-toplevel)"
C:/Users/HP/.conda/envs/torch5060/python.exe -u -m gs_pino_fno_phys.train_pino \
--mode twostage --model tkno_lite \
--train-data dn_fno_2608/data_v5/dn/train.npz \
--val-data dn_fno_2608/data_v5/dn/val.npz \
--n-train 500 --seed 1 --epochs 800 \
--phys-weight 0.1 --ip-weight 1.0 --j-weight 1.0 \
--stage1-threshold 0.03 --stage1-max-epochs 300 --stage2-ramp-epochs 30 \
--out-dir dn_fno_2608/experiments/exp311_tkno_lite_pino_twostage_n500
```

产物约定 (每实验目录): best.pt (含 model 键与 pod_basis)、
history.json (逐 epoch 损失/val)、args.json、metrics.json、
figures/ (fig1 best/worst 场对比、fig2 指标分布、fig3 几何定位 +
stats_per_sample.json)、train.log / eval.log。

新架构接入: 在 models_alt.py 实现 forward(x) -> (B,C,65,65) + count_params(),
注册进 MODEL_REGISTRY, 训练管线零改动 (两阶段逻辑与骨架完全解耦)。

8. 术语表

术语	含义
GS 方程	Grad-Shafranov: 托卡马克平衡的核心偏微分方程
free-boundary	自由边界: 边界形状由线圈电流决定而非给定
磁通 ψ / 磁面	极向磁通场; 等值线 = 磁力线 = 磁面
X 点 / O 点	分离面的临界点: X 形分岔点 / 磁轴中心点
coil 分离	总场 = 等离子体场 + Σ 线圈电流 $\times$ Green 函数, 网络只学前者
模态 (modes)	谱卷积保留的低频傅里叶分量数 (16 $\times$ 16 等)

术语	含义
感受野	输出像素能看到的输入区域
谱卷积	频域乘可学习系数再逆变换 = 全局混合核
自注意力	token 间内容自适应的全局加权求和
z-score	减均值除标准差，把量纲不同的量拉平
嵌套子集	固定种子抽取的子集，跨 N 实验可比较
mask	等离子体核心区二值图；物理损失只在 mask 内
POD/SVD	数据主导模式分解；低秩基的来源
B-spline	分段多项式基，KAN 的可学习激活
两阶段 PINO	阶段1 监督拟合 → 阶段2 物理微调
warm-up ramp	物理权重从 0 线性爬升，防止阶段切换爆炸
pde_scale / ip_scale	物理量归一化尺度 (0.362 Wb/m ² 、5.51e5 A)
早停 patience	验证指标连续 N 个 epoch 无改进就停 (75)
phase-aware best	阶段1/2 各存最佳权重，artifact 优先阶段2

9. 延伸阅读

- 系列总览：[EXPERIMENTS.md](#)（全部实验台账与结论链）
- 架构选型调研：[ARCHS_SURVEY.md](#)（文献证据 + 候选矩阵）
- 数据说明：[data_v5/README.md](#)
- 每实验细节：`experiments/expXXX_*/README.md`（结果表 + 归因分析）
- 文献锚点：FNO (Li et al. 2021)、DeepONet (Lu et al. 2021)、POD-DeepONet (Lu et al. 2022)、TKNO (arXiv:2511.19114, 同一 GS 任务)、TCV PINO 部署 (arXiv:2606.09487)、FNO 自由边界 DN (arXiv:2608.05555, 本仓库复现的论文)