

exp307 — PI-DeepONet 加宽 (branch/trunk 256→384, 0.60M→1.34M)

实验日期: 2026-09-01 | 状态: **完成** (N=500, seed 1, data_v5/dn 单一位形)

数据: data_v5/dn/ (MAST DN, 65×65, 2000/500/500, 无墙) ——与 exp102 逐项一致

对照: exp304 (PI-DeepONet 两阶段, 0.802%, psi 平 FNO 但 J/lp 弱 2×)

结论速览: **加宽成功修复 J/lp 短板** (本系列 DeepONet 的正面答案) ——

test rel L2 0.7575% (exp304 0.802%, -5.6%; 同时低于 FNO 0.800%)、

lp 0.210% (exp304 0.384%, -45%, 反超 exp302 的 0.213%)、**J 2.13%**

(-0.48pp)、**X 点 0.59/0.51 cm** (exp304 0.73/0.70) ——exp304 §5 预告的

"容量需加大"被 1.34M 参数 (2.2×) 验证为正确诊断, J/lp 弱 2× 确系容量

不足而非分支-主干分解缺陷

1. 目标

exp304 的 DeepONet 结论是"容量奇迹": 0.60M 参数 psi 精度与 FNO 统计不可区分, 但 **J 2.61%** (FNO 的 1.9×)、**lp 0.38%** (1.8×)、**GS 残差 0.0298 (2×)**

——J 是 ψ 的二阶导场, 0.6M 容量学 ψ 主任务绰绰有余、承载二阶导场不足。

exp304 README §6 与 §5 解读都预告了直接选项: "**branch/trunk 宽度翻倍是直接选项, 未做超参搜索**".

本实验只做一件事: $p=\text{hidden}=256\rightarrow384$ (branch_psi/branch_j/trunk 三路同宽

加宽), **0.601,600 → 1,344,768 参数 (2.2×)**。训练超参与 exp102/exp304

逐项一致——加宽是唯一的变量, exp304→exp307 的增量即容量的净贡献。

两阶段方案与 exp102 逐项一致:

阶段1 损失 = $\text{MSE}(\text{psi_plasma}, z) + w_j \cdot \text{masked MSE}(J, z)$ (core mask 内)

阶段2 损失 = 阶段1 + $w_{\text{pde}} \cdot \|\Delta \cdot \psi_{\text{pred}} + \mu_0 \cdot R \cdot J_{\text{pred}}\|^2$ (core mask 内) + $w_{\text{lp}} \cdot \|\sum J \cdot dA - \text{lp}\|/\text{ip_scale}\|^2$

- 模型双输出通道: 通道 0 = psi_plasma (z 域), 通道 1 = $J\phi$ (z 域)
- 切换条件: 阶段1 val rel L2 < 3% 自动切阶段2 (--stage1-max-epochs 300 兜底)
- **物理权重预热**: 阶段2 的 $w_{\text{pde}}/w_{\text{lp}}$ 从 0 线性 ramp 到目标值 (30 epochs)

架构: branch ×2 (各 16→384×3 层 GELU, 输入 = $x[:,2:].\text{mean}((2,3))$)

即 z-score 标量), 共享 trunk MLP ((R,Z)→384×3 层, 输入 = 归一化网格坐标,

`x[:,0:2]` reshape (B,4225,2)), 输出 einsum 点积 $\rightarrow$ (B,2,65,65);
trunk 末层权重 $\times 0.1$ 小初始化 (同 exp304 约定); **1,344,768 参数**。

2. 输入通道 (18 通道, 同 exp102/exp304 coils 模式)

#	通道	含义/单位	来源
1	R	网格 R 坐标 ([-1,1])	固定 MAST 65×65 (trunk 输入)
2	Z	网格 Z 坐标 ([-1,1])	固定 MAST 65×65 (trunk 输入)
3	Ip	等离子体电流 (A)	params[0] (branch 输入)
4	paxis	磁轴压强 (Pa)	params[1] (branch 输入)
5	fvac	真空通量函数 f (Wb/m)	params[2] (branch 输入)
6	alpha_m	剖面形状指数 m	params[3] (branch 输入)
7	alpha_n	剖面形状指数 n	params[4] (branch 输入)
8–17	I_P2U ... I_P6L	上下偏滤器线圈电流 (A)	coil_currents[0:10] (branch 输入)
18	I_P1 (Solenoid)	中心螺线管电流 (A)	coil_currents[10] (branch 输入)

(DeepONet 的分支输入 = 18ch 中除 R/Z 外的 16 个标量通道——模型内部
`x[:,2:].mean((2,3))`), 广播后每像素相同故取 mean 即原值; 数据管线与
exp102 完全同口径, 零改动。)

3. coil 分离 (同 exp102)

网络只预测 **psi_plasma** (+Jφ); 评估时 $\text{psi_total} = \text{psi_plasma_pred} + \sum_k I_k \cdot G_k$ (greens 恒等式
验证 max diff 6e-8 Wb)。物理残差只定义在
等离子体场上——线圈场占 |psi_total| 幅值 183%、|Δ*ψ_coils| 峰值 27.9 vs
等离子体 0.89, 残差落在 psi_total 上会被线圈导体奇性主导。详见 exp101 README §3。

4. 训练设置

N=500 (全量 2000 池嵌套子集, perm seed 12345), seed 1, AdamW lr 1e-3
wd 1e-4, ReduceLROnPlateau (patience 20, factor 0.5, min_lr 1e-5), batch 16,
800 epochs。模型 **PIDeepONet2d(deeponet_wide)**: p=384, hidden=384, layers=3 ,

1,344,768 参数 (exp304 的 2.2×)。PDE 残差 interior (1:-1,1:-1) 二阶中心差分，core mask 内 masked mean((res/pde_scale)²)，pde_scale=0.362 Wb/m²；Ip 损失用 ip_scale=5.51e5 A 归一化。

阶段切换：阶段1 val rel L2 第 44 epoch 达 2.96% < 3% 阈值 → 切阶段2 (与 exp304 的 e42 同档——加宽没有拖慢阶段1)。阶段2 全程 756 epochs 中 val 从 2.96% 平滑降到 **0.8771%** (@ e749, exp304 为 0.9528% @ e795, -0.076pp)。**phase-aware best:** artifact 取阶段2 best (best val rel L2 **0.8771%** @ epoch 749)。

5. 结果 (test n=500, DN-only)

指标	exp307 (DeepONet wide)	exp304 (DeepONet)	exp102 (FNO twostage)
rel_l2_plasma mean / median / p95 (%)	0.87 / 0.64 / 1.99	0.92 / 0.69 / 2.06	0.90 / 0.74 / 1.70
rel_l2_total mean / median / p95 (%)	0.76 / 0.57 / 1.69	0.80 / 0.63 / 1.87	0.80 / 0.64 / 1.59
rmse_phys (Wb) plasma / total	2.88e-4 / 2.88e-4	3.04e-4 / 3.04e-4	2.97e-4 / 2.97e-4
GS 残差 core mask: pred / truth	0.0234 / 0.0040	0.0298 / 0.0040	0.0151 / 0.0040
Ip 相对误差 mean / median / p95 (%)	0.21 / 0.15 / 0.58	0.38 / 0.34 / 0.84	0.21 / 0.16 / 0.54
J rel L2 mask 内 mean / median / p95 (%)	2.13 / 1.92 / 3.67	2.61 / 2.36 / 4.87	1.36 / 1.11 / 2.66
X 点定位误差 lo / up (cm)	0.59 / 0.51	0.73 / 0.70	0.60 / 0.63
O 点误差 / 分离面 mean (cm)	0.20 / —	0.24 / —	0.21 / 0.34

解读：

- 1. 加宽是 exp304 短板的正解：rel_l2_total **0.7575% vs 0.802% (-5.6%)**、Ip **0.210% (-45%，与 exp302 的 0.213% 打平)**、J 2.13% (-0.48pp，

- p95 -1.2pp)、X 点 -19%/-27%——exp304 §5 的容量诊断 ("J 是 ψ 二阶导, 需承载微结构的容量") 被 2.2 $\times$ 参数直接验证; J/lp 弱不是分支-主干分解的缺陷, 是 0.6M 容量不够
2. **psi 精度同时改善**: plasma 0.87% (exp304 0.92%) ——加宽不是只补 J/lp, ψ 主任务也从更多容量受益 (p95 1.99 vs 2.06 略差但 mean/median 更好)
 3. **与 FNO 的对照升级**: exp304 是"统计不可区分", exp307 是**明确小胜** (0.7575% vs 0.800%, -5%) ——DeepONet 加宽后从"容量奇迹打平"变成 "1.34M 参数超越 4.2M 的 FNO"; 分支-主干分解 + 足够宽度的组合是 UFNO 之外的第二条可行路线
 4. **代价**: 训练约 27 min (exp304 约 20 min, +35%), 慢于 FNO 的 15.4 min ($\sim 1.8\times$), 但参数只有 FNO 的 0.32 $\times$ (1.34M vs 4.21M) ——下游需要 J/lp 时这是明确的正向性价比 (exp304 §6 的"psi 窄模型 + J 宽模型"两模型策略不再需要, 一个宽模型全覆盖)

6. 局限 (加宽特有)

- **单点扫描**: 384 是"翻倍"的直观选择, 不是扫描出的最优——若收益有限, "容量已够/容量曲线饱和"与"这个宽度不凑巧"无法区分 (下一档 512 是唯一确认手段, 成本 2 $\times$)
- **加宽 vs 加深**: 只加宽不加深 (layers=3 不变); branch 更深 (4-5 层) 是另一个正交方向, 未做
- **0.6M $\rightarrow$ 1.34M 的成本**: exp304 训练 ~ 20 min (系列最快), 加宽后计算量 $\sim 2\times$, 若 J/lp 收益 $< 2\times$ 的计算代价, "psi 用途用窄模型、下游 J 用途用宽模型"仍是更优策略——由本实验的收益大小决定
- **小样本过拟合风险**: N=500 下 2.2 $\times$ 参数, 训练/val 曲线若出现分叉, 加宽方向不成立 (val 主导的 phase-aware best 会部分掩盖)

7. 复现

```
bash dn_fno_2608/scripts/run_exp307_308_pino.sh train    # 训练 (含 exp308)
bash dn_fno_2608/scripts/run_exp307_308_pino.sh eval    # 评估 (含 exp308)
# 单独:
cd "$(git rev-parse --show-toplevel)"
C:/Users/HP/.conda/envs/torch5060/python.exe -u -m gs_pino_fno_phys.train_pino \
  --mode twostage --model deeponet_wide --train-data dn_fno_2608/data_v5/dn/train.npz \
  --val-data dn_fno_2608/data_v5/dn/val.npz --n-train 500 --seed 1 \
  --epochs 800 --phys-weight 0.1 --ip-weight 1.0 --j-weight 1.0 \
  --stage1-threshold 0.03 --stage1-max-epochs 300 --stage2-ramp-epochs 30 \
  --out-dir dn_fno_2608/experiments/exp307_pideeponet_wide_pino_twostage_n500
```

产物同 exp102 约定: best.pt (含 model 键)、history.json、args.json、metrics.json、train.log / eval.log、figures/ (fig1_best_worst_psi / fig2_field_stats / fig3_geometry_stats + stats_per_sample.json)。